VitaStress — Riprodurre la Figura 4

Lavoro concluso · percorso, codice finale e confronto con il paper · Tirocinio, Interfacce uomo-macchina

1. Il contesto

L'esperimento. Ogni persona indossa un braccialetto per circa un'ora e mezza e passa per quattro situazioni, chiamate **fasi**: riposo (baseline), calcolo mentale (cognitive), corsa (physical), discorso in pubblico (public).

I dati. Il braccialetto registra di continuo una lista di orari e valori, senza sapere cosa sta facendo la persona:

```
orario      battito
20:08:30    74
20:09:00    73
...
20:28:00    88
```

La soluzione. Il file delle **annotazioni** dice quando inizia e finisce ogni fase. Confrontando gli orari, ogni valore riceve la sua fase:

```
orario      battito    fase
20:08:30    74         riposo      ← fra 20:08 e 20:18
20:28:00    88         discorso    ← fra 20:27 e 20:32
```

> **Tutto il codice serve a fare questo:** aggiungere la colonna «fase» ai dati, e poi disegnare un violino per fase.

2. Il grafico

La **Figura 4** del paper mostra **6 misure** (battito, sudore, temperatura della pelle, movimento X, Y, Z) nelle **4 fasi**, mettendo insieme tutti i 21 soggetti.

Come si legge un violino

- la **riga bianca** è la **mediana**: il valore che sta a metà
- la **scatolina** contiene la metà centrale dei valori
- la **larghezza** dice dove si concentrano i valori: largo = tanti, stretto = pochi
- violino più in alto degli altri = in quella fase la misura sale

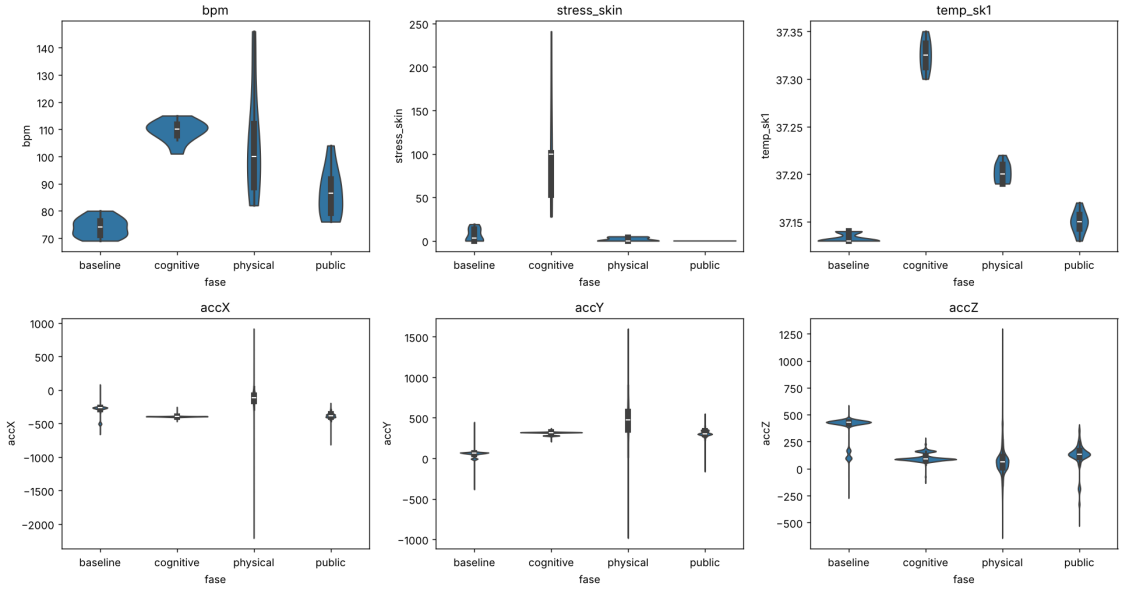
Cosa dice il paper

misura	cosa succede
battito	basso a riposo, più alto in calcolo e discorso, massimo nella corsa
sudore	massimo durante il calcolo
temperatura pelle	massima nella corsa, minima nel calcolo
movimento X e Y	quasi fermo nel calcolo, molto variabile nella corsa
movimento Z	a riposo spostato in alto per la gravità

3. Il percorso

Per capire il meccanismo il lavoro è stato costruito in tre tappe, dalla più semplice alla completa. Nel notebook finale resta solo l'ultima.

tappa	cosa	cosa ha insegnato
1	battito, 1 persona	tagliare i dati per fase; il battito a 0 è un errore del sensore; cut=0 per non inventare code
2	6 misure, 1 persona	una funzione riutilizzabile per tutte le misure
3	6 misure, 21 persone	controlli sui dati, media dell'accelerometro, standardizzazione per persona



Tappa 2 — sei misure, una persona (840e79d3), valori originali. Le scale sono diverse fra le misure e fra le persone: per questo nella tappa 3 serve standardizzare.

4. Il codice finale, fase per fase

Fase 0 · Setup

```
import os
import pandas as pd
import numpy as np
import seaborn as sns
import matplotlib.pyplot as plt

if not os.path.exists("VitaStress"):
    !git clone https://github.com/paulvincenz/VitaStress.git

DATA = "VitaStress/data"
```

Carica le librerie (**pandas** per le tabelle, **numpy** per i calcoli, **seaborn** e **matplotlib** per i grafici) e scarica il dataset solo se non c'è già.

Fase 1 · Persone

```
persone = sorted([c.replace("id_", "") for c in os.listdir(DATA) if c.startswith("id_")])
print("Persone:", len(persone))
```

Legge i nomi delle cartelle, tiene quelle che iniziano con `id_` e toglie il prefisso: restano i 21 codici delle persone. `sorted` li mette sempre nello stesso ordine.

Fase 2 · Orari delle fasi

```
fasi = {"baseline": "baseline", "cognitive": "cognitive",
        "public": "public speaking", "physical": "physical"}

def trova_orari(persona):
    cartella = DATA + "/id_" + persona + "/" + persona + "_"
    ann = pd.read_csv(cartella + "annotation.csv")
    ann["timestamp"] = pd.to_datetime(ann["timestamp"], format="mixed")
    ann["evento"] = ann["Button Name"].astype(str).str.lower().str.replace(":", "").str.strip(" []'")
    orari = {}
    for fase in fasi:
        nome = fasi[fase]
        inizio = ann[ann["evento"].str.startswith(nome + " start")]["timestamp"]
        fine = ann[ann["evento"].str.startswith(nome + " stop")]["timestamp"]
        if len(inizio) == 0 or len(fine) == 0:
            print(persona[:8], fase, "-> manca inizio o fine, salto")
            continue
        durata = (fine.iloc[0] - inizio.iloc[0]).total_seconds() / 60
        if durata <= 0 or durata > 30:
            print(persona[:8], fase, "-> durata strana:", round(durata, 1), "min, salto")
            continue
        orari[fase] = (inizio.iloc[0], fine.iloc[0])
    return orari
```

- `fasi`: a sinistra il nome corto della fase, a destra come compare nelle annotazioni
- `to_datetime` trasforma gli orari da testo a orari veri, confrontabili
- la riga di `evento` pulisce i nomi: minuscolo, niente due punti, niente simboli. «Physical: Start» e «Physical Start» diventano uguali
- per ogni fase cerca la riga che comincia con «nome start» e quella con «nome stop», e ne prende l'orario
- **due controlli**: se manca un pulsante, o la fase dura meno di 0 o più di 30 minuti, la fase viene saltata e stampata
- risultato: per ogni persona un elenco fase → (inizio, fine)

Fase 3 · Tagliare ed etichettare

```
def taglia(dati, colonna, orari):
    risultato = []
    for fase in orari:
        inizio, fine = orari[fase]
        pezzo = dati[(dati["date"] >= inizio) & (dati["date"] <= fine)].copy()
        pezzo["fase"] = fase
        risultato.append(pezzo[[colonna, "fase"]])
    return pd.concat(risultato, ignore_index=True)
```

- **è il cuore del lavoro**: per ogni fase tiene solo le righe registrate dopo l'inizio *e* prima della fine (& = «e») e ci scrive accanto la fase
- `pd.concat` incolla i pezzi delle quattro fasi; `ignore_index=True` rinumera le righe da zero

Fase 4 · Tutte le persone, tutte le misure

```
variabili = [("activity", "bpm"), ("emography", "stress_skin"), ("temperature", "temp_sk1"),
             ("acc", "accX"), ("acc", "accY"), ("acc", "accZ")]

tutte = []
for persona in persone:
    orari = trova_orari(persona)
    cartella = DATA + "/id_" + persona + "/" + persona + "_"
    for file, colonna in variabili:
        dati = pd.read_csv(cartella + file + ".csv", usecols=["date", colonna])
        dati["date"] = pd.to_datetime(dati["date"], format="mixed")
        if file == "acc":
            dati = dati.resample("30s", on="date").mean().reset_index()
        tab = taglia(dati, colonna, orari)
        tab = tab.rename(columns={colonna: "valore"})
        if colonna == "bpm" or colonna == "temp_sk1":
            tab["valore"] = tab["valore"].replace(0, np.nan)
        tab["grezzo"] = tab["valore"]
        tab["valore"] = (tab["valore"] - tab["valore"].mean()) / tab["valore"].std()
        tab["persona"] = persona
        tab["variabile"] = colonna
        tutte.append(tab)

tutte = pd.concat(tutte, ignore_index=True)
```

- `variabili`: le sei misure, ognuna con il file in cui si trova e il nome della colonna
- due cicli uno dentro l'altro: per ogni persona, per ogni misura
- `usecols` legge solo le due colonne utili: molto più veloce sui file grandi
- `resample("30s").mean()`: l'accelerometro misura 32 volte al secondo, le altre misure ogni 30 secondi. La media ogni 30 secondi le mette sullo stesso ritmo
- **pulizia**: battito 0 e temperatura 0 °C sono errori del sensore e diventano `NaN` (mancante). Gli zeri del sudore invece sono valori veri e restano
- `grezzo` conserva il valore originale, per il confronto con il paper
- la riga con `mean()` e `std()` è la **standardizzazione per persona** (sezione 5)
- tutte le misure finiscono in un'unica tabella, distinte dalla colonna `variabile`

Fase 5 · Figura 4

```
ordine = ["baseline", "cognitive", "physical", "public"]

plt.figure(figsize=(15, 8))
for i, (file, colonna) in enumerate(variabili):
    plt.subplot(2, 3, i + 1)
    sns.violinplot(data=tutte[tutte["variabile"] == colonna], x="fase", y="valore",
                   cut=0, order=ordine)
    plt.title(colonna)
plt.tight_layout()
plt.show()
```

- `plt.subplot(2, 3, i + 1)` sceglie il riquadro in una griglia 2×3
- `tutte[tutte["variabile"] == colonna]` tiene solo le righe della misura da disegnare
- `violinplot` mette le fasi in orizzontale e i valori in verticale, un violino per fase; `cut=0` ferma il violino ai valori veri; `ordine` è lo stesso del paper

Fase 6 · Confronto con il paper

```
print(tutte.groupby(["variabile", "fase"])["grezzo"].median().unstack()[ordine].round(2))

sudore = tutte[tutte["variabile"] == "stress_skin"]
print((sudore.groupby("fase")["grezzo"].apply(lambda s: (s == 0).mean() * 100)).round(0))
```

Calcola le mediane dei valori **originali** per misura e fase, e la percentuale di zeri del sudore. Servono a capire le differenze con il paper (sezione 7).

5. La standardizzazione per persona

Due persone, Anna e Marco. Sotto stress entrambi alzano il battito di 10:

	riposo	calcolo
Anna	60	70
Marco	85	95

Mettendo tutti i numeri insieme, il riposo di Marco (85) sta sopra il calcolo di Anna (70): le fasi si confondono. Il grafico mostrerebbe soprattutto che Marco ha il cuore più veloce. La soluzione è confrontare ognuno **con sé stesso**, sottraendo la sua media (Anna 65, Marco 90):

	riposo	calcolo
Anna	−5	+5
Marco	−5	+5

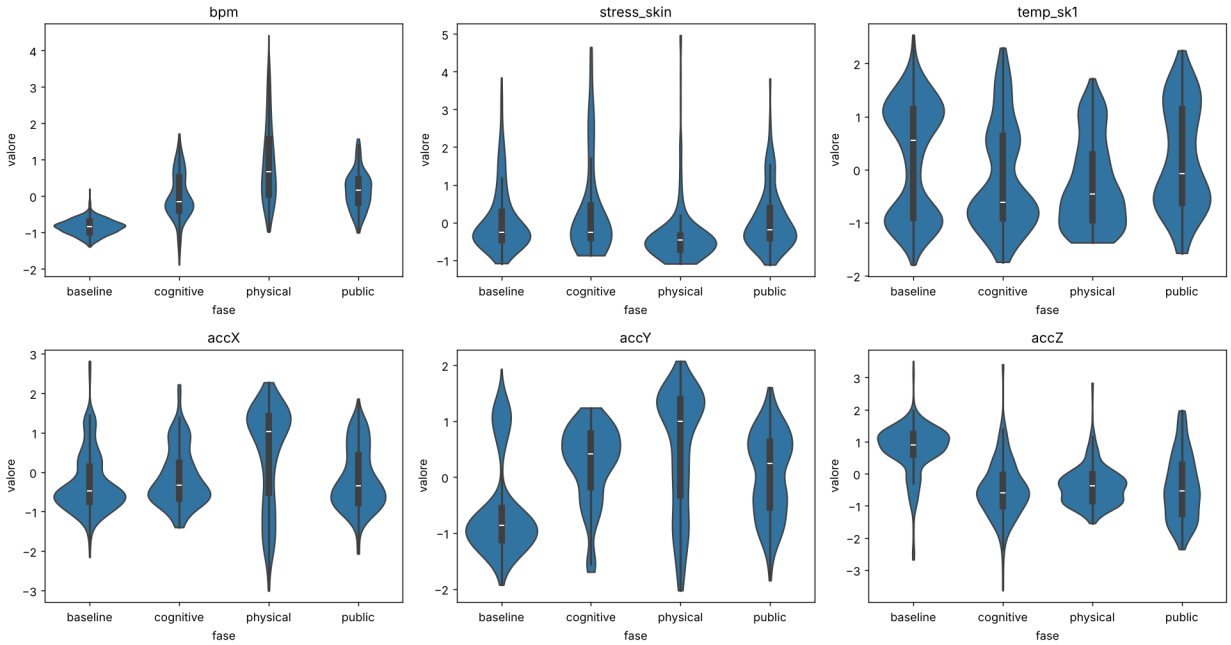
Poi si divide per quanto ciascuno varia di solito (la deviazione standard), così tutti finiscono sulla stessa scala:

```
valore standardizzato = (valore - media della persona) / deviazione standard della persona
```

- **0** = il valore normale di quella persona
- **+1** = un po' sopra il suo solito, **+3** = molto sopra
- **−1** = un po' sotto il suo solito

> **Cosa dice il paper.** Dichiara di usare variabili standardizzate (z-score) per la PCA, e i valori della Figura 4 (da circa −4 a +4) suggeriscono lo stesso. Non dice se per persona o su tutti insieme: abbiamo scelto per persona.

6. Il risultato



La nostra Figura 4: sei misure, 21 soggetti, valori standardizzati per persona.

Come si legge, riquadro per riquadro

riquadro	cosa dice
bpm	basso a riposo (−0,8), sale nelle fasi di stress, massimo nella corsa (+0,7). Il violino del riposo è corto: tutti tranquilli allo stesso modo
stress_skin	mediane tutte poco sotto lo zero: sembra piatto, ma è un effetto della standardizzazione (sezione 7)
temp_sk1	cambia poco fra le fasi
accX, accY	la corsa ha il violino più lungo e più alto: è la fase con più movimento
accY, riposo	due «pance»: 16 persone sotto lo zero, 4 sopra. Due gruppi con il braccio in posizioni diverse da seduti
accZ	a riposo in alto (+0,9): è la gravità sul polso fermo e appoggiato

7. Differenze con il paper

misura	coincide?	perché
battito	sì	
movimento X, Y, Z	sì	
sudore	nel grafico no, nei numeri sì	la standardizzazione appiattisce le differenze
temperatura	no	forse un'altra colonna, o deriva nel tempo

Mediane dei valori originali

misura	riposo	calcolo	corsa	discorso
bpm	76	95	109	96
stress_skin	14	22	1,5	18
temp_sk1 (°C)	37,22	37,26	37,22	37,26

Sudore: i dati danno ragione al paper. Nei valori originali è massimo nel calcolo (22) e quasi zero nella corsa (1,5). Ma `stress_skin` è pieno di zeri (dal 19% al 45% a seconda della fase) e ha pochi valori molto alti. È come una classe in cui quasi tutti prendono 0 e due studenti 100: misurando «quanto sei sopra o sotto la media», quasi tutti risultano un po' sotto, in ogni classe. Le fasi sembrano uguali, anche se non lo sono.

Temperatura: qui la differenza è vera. Nei valori originali le fasi stanno tutte fra 37,22 e 37,26 °C. Il paper descrive una temperatura massima nella corsa. Possibili cause: un'altra colonna di temperatura (c'è anche `heat_flux_sensor_temperature`), oppure una deriva lenta, per cui la temperatura riflette più il momento dell'esperimento che la fase. Senza il codice degli autori non si può sapere.

> **Il grafico non è sbagliato: risponde a una domanda diversa.** Dice se il valore tipico di una fase è sopra o sotto la media di ciascuna persona. Per dati regolari come il battito coincide con «in quale fase la misura è più alta»; per dati sbilanciati come il sudore no. Riprodurre la figura ha permesso di accorgersene: è un'osservazione che il paper non fa.

8. Decisioni prese

#	decisione	motivo
1	battito 0 → mancante	errore del sensore
2	temperatura 0 °C → mancante	errore del sensore (una persona, fase cognitive)
3	zeri di stress_skin tenuti	è un indice: lo zero è un valore vero
4	violin plot con cut=0	niente code oltre i dati veri
5	a5e823ad: riposo escluso	82 minuti, pulsante premuto male
6	accelerometro: media ogni 30 s	stesso ritmo delle altre misure
7	standardizzazione per persona	confrontare ognuno con sé stesso
8	temperatura	questione aperta
9	standardizzazione del sudore	da rivedere prima delle feature (es. mediana invece della media)

In una riga

annotazioni → orari delle fasi → per ogni persona e misura si tengono i valori dentro quegli orari e ci si scrive la fase → pulizia → standardizzazione per persona → un violino per fase.

Lo stesso schema servirà per costruire la tabella da dare ai modelli: cambierà solo l'ultimo passo, che invece di disegnare calcolerà le feature.