VitaStress — dove siamo e dove andiamo

Preparazione alla call di aggiornamento: cosa ho fatto nei passi 1 e 2, quali feature usano gli autori, quali sono i prossimi passi e cosa chiedere alla prof. Matteo — tirocinio «Interfacce uomo-macchina», Università dell'Insubria — ottobre 2026.

In breve

Nella mail alla prof ho descritto tre blocchi: (1) rifare l'esperimento degli autori, (2) cambiare le feature usando i dati grezzi, (3) provare una rete neurale. La prof ha confermato e ha chiesto: «fate una lista di quelle che hanno usato gli autori del secondo paper e poi vediamo se riusciamo ad aggiungerne altre».

Fatto: il blocco (1), cioè la tabella degli autori (passo 1) e il loro classificatore (passo 2).
Pronta: la lista delle feature degli autori (sezione 4).

Mi fermo qui e chiedo alla prof come proseguire. Ho due idee che non erano nel piano concordato (sezione 3) e le porto come domande, non come lavoro già deciso.

1. La mappa del progetto

La regola che seguo: **prima rifaccio il risultato degli autori, poi cambio una cosa alla volta**, sempre con la stessa validazione. Così ogni differenza nei risultati ha una causa sola.

passo	cosa	stato	corrisponde nella mail a
1	Tabella dei dati come gli autori (una riga ogni 30 s, 12 feature)	fatto	blocco 1 — replica
2	Sei classificatori, stress / non stress, leave-one-subject-out	fatto	blocco 1 — replica
3	Fisiologia contro movimento (altre righe della Tabella 4)	da chiedere	non previsto: domanda alla prof
4	Feature nuove dai segnali grezzi	da fare	blocco 2
5	Classificatori con le feature nuove	da fare	blocco 2
6	Rete neurale (MLP)	da fare	blocco 3
7	Conclusioni e relazione	da fare	—

Il passo 1 in due righe

Dai file del braccialetto costruisco una tabella con **una riga ogni 30 secondi** e 12 colonne: battito (*bpm*), sudore (*stress_skin*), temperatura (*temp_sk1*) e media, deviazione standard e varianza dei tre assi dell'accelerometro. Tengo solo i blocchi dentro una fase, tolgo le righe incomplete e normalizzo ogni persona rispetto a sé stessa (z-score). Risultato: **1.145 righe** (403 riposo, 195 calcolo, 205 discorso, 342 corsa), di cui il 64,8% stress. Gli autori ne hanno circa 1.114: siamo vicini.

2. Passo 2 — il classificatore binario

A cosa serve

Verificare che, con gli stessi dati e lo stesso metodo, ottengo lo stesso risultato degli autori (Random Forest all'89%, Tabella 4). Se la replica non torna, nessun confronto successivo ha senso: qualunque miglioramento potrebbe dipendere da una differenza di preparazione dei dati e non dalle nuove feature.

Come funziona

- **Compito:** riposo = non stress (0); calcolo, discorso e corsa = stress (1).
- **Validazione leave-one-subject-out:** addestro il modello su 20 persone e lo provo sulla 21ª, poi ripeto per tutte e 21. Il modello viene sempre provato su una persona che non ha mai visto: è la domanda realistica («funziona su un utente nuovo?»).
- **Sei classificatori**, gli stessi del paper, con parametri standard: Logistic Regression, Random Forest, Decision Tree, LDA, XGBoost, kNN.
- **Misure:** accuracy (quante risposte giuste) e F1 macro (media della F1 delle due classi: non si lascia ingannare dal fatto che lo stress è il 65% delle righe).

Risultati

classificatore	noi (accuracy)	paper (Tabella 4)	differenza
Logistic Regression	0,92	0,88	+0,04
Random Forest	**0,93**	**0,89**	+0,04
Decision Tree	0,91	0,88	+0,03
LDA	0,91	0,88	+0,03
XGBoost	0,94	0,87	+0,07
kNN	0,87	0,87	0,00
rispondere sempre «stress»	0,65	—	soglia minima

Cosa saper dire alla prof

- **La replica torna.** Siamo 3–7 punti sopra il paper, con deviazioni standard simili (RF 0,93 ± 0,11 contro 0,89 ± 0,11). Una differenza di pochi punti è normale: non conosciamo i loro iperparametri né tutti i dettagli della pulizia.
- **Possibile causa della differenza:** ho tolto le temperature a 0 °C (errore del sensore) e il riposo di 82 minuti della persona *a5e823ad*; dalla Figura 4 del paper sembra che loro non l'abbiano fatto.
- **Tre risultati da saper spiegare bene** (pagine seguenti): il riferimento 0,65, le due persone su cui il modello sbaglia, e quanto il modello usa il movimento.

Tre risultati del passo 2, spiegati

A. Il riferimento è 0,65, non 0,50

Nella tabella 742 righe su 1.145 sono stress (64,8%). Un «modello» che risponde sempre «stress», senza guardare i dati, ne azzecca quindi circa il 65%. Questo è il **livello minimo da battere**: un classificatore è utile solo se va oltre.

Lo 0,50 (tirare una moneta) sarebbe il riferimento solo con due classi della stessa grandezza. Qui non lo sono. Quindi Random Forest a 0,93 non è «43 punti sopra il caso», ma **28 punti sopra il minimo**: resta un buon risultato, ma va letto così.

modello	accuracy	F1 stress	F1 non stress	F1 macro
sempre «stress»	0,65	0,79	0,00	**0,39**
Random Forest	0,93	—	—	**0,91**

Per questo riportiamo anche la **F1 macro**: è la media della F1 delle due classi. Il modello «sempre stress» non indovina mai il riposo, quindi la sua F1 su «non stress» è 0 e la F1 macro crolla a 0,39. Un modello che ignora una classe viene smascherato.

B. Le due persone su cui il modello sbaglia

Con il leave-one-subject-out ogni persona fa una volta da prova: si ottengono **21 accuracy**, una per persona. Lo 0,93 è la loro media e il ± 0,11 dice quanto variano. 19 persone sono sopra 0,85; due si fermano a 0,62–0,63. Guardando gli errori fase per fase, **sbagliano in modo opposto**:

persona	riposo	calcolo	corsa	discorso	errore tipico
ddca342b	**2 / 20**	9 / 10	16 / 17	6 / 6	riposo scambiato per stress
a5e823ad	escluso	**4 / 11**	**9 / 14**	9 / 10	stress scambiato per riposo

Righe classificate correttamente sul totale della fase (Random Forest).

ddca342b: il braccialetto è girato

Da fermi l'accelerometro misura soprattutto la gravità, quindi la media di ogni asse durante il riposo dice **come è orientato il polso**. Per 20 persone su 21 l'asse X è negativo e l'asse Z positivo. ddca342b è l'unica con i segni invertiti:

durante il riposo	asse X	asse Y	asse Z	intensità della gravità
altre 20 persone	da −502 a −68	da −192 a +165	da +79 a +492	428–518
ddca342b	**+442**	+82	**−106**	462

Valori grezzi del file acc, media delle righe di riposo. L'intensità della gravità è normale: il sensore funziona, è solo **orientato al contrario** (per esempio indossato sull'altro polso o girato).

- **Perché il modello sbaglia:** dalle altre 20 persone ha imparato una regola sulla postura, cioè «asse Z alto e asse Y basso = riposo». Dopo la normalizzazione, il riposo di ddca342b ha invece asse Z basso (−0,43) e asse Y alto (+0,69): proprio il profilo che per gli altri corrisponde alle fasi di stress. Il battito dice «riposo» (−0,89, come gli altri), ma il modello si fida della postura.
- **Verifica:** rifacendo il classificatore **senza** le medie dell'accelerometro, ddca342b sale a 0,75 (12 riposi giusti su 20); con **solo** battito, sudore e temperatura sale a 0,91 (20 su 20). Quindi il problema è l'orientamento, non i suoi segnali fisiologici.

- **Cosa significa:** è la prova concreta che il modello usa la **postura del polso** per decidere. Una feature come la magnitudine del movimento (passo 4), che non dipende dall'orientamento, eviterebbe questo problema. Il paper non ne parla.

Come raccontarlo alla prof

«Guardando l'accuracy persona per persona ho notato che due partecipanti andavano molto peggio degli altri, intorno a 0,62. Per capire il motivo mi sono fatto aiutare da Claude: abbiamo guardato gli errori fase per fase e i valori grezzi dell'accelerometro.»

«Per ddca342b è venuto fuori che il modello sbaglia quasi solo il riposo, 18 righe su 20. Il motivo è che è l'unica persona con il braccialetto orientato al contrario: durante il riposo l'asse X è positivo e l'asse Z negativo, mentre per tutti gli altri è il contrario. La gravità misurata è normale, quindi il sensore funziona, è solo girato.»

«Il modello ha imparato dagli altri che una certa posizione del polso vuol dire riposo, e su questa persona sbaglia. Per verificarlo abbiamo tolto le medie dell'accelerometro e sale a 0,75; con solo battito, sudore e temperatura arriva a 0,91 e riconosce tutti i riposi.»

«Secondo me è la conferma concreta che il modello si appoggia sulla postura. Una feature come la magnitudine del movimento, che non dipende dall'orientamento, dovrebbe risolverlo.»

Prima della call: aggiungi tu la verifica al notebook 02 (accuracy per fase di ddca342b e medie dell'accelerometro durante il riposo), così se la prof chiede di vederla puoi mostrarla e spiegare ogni passaggio.

a5e823ad: manca il riposo

- **Il dato:** il suo riposo dura 82 minuti invece di 10 (probabile errore nelle annotazioni) ed è stato escluso. Per questa persona ci sono solo righe di stress.
- **Perché il modello sbaglia:** la normalizzazione toglie a ogni valore la media della persona. Per questa persona quella media è calcolata solo sullo stress, quindi dopo la normalizzazione circa metà delle sue righe di stress risulta «sotto la sua media» e assomiglia al riposo delle altre persone.
- **Verifica:** gli errori sono proprio stress scambiato per riposo (7 su 11 nel calcolo, 5 su 14 nella corsa). Con solo la fisiologia resta bassa (0,69): il problema non è il movimento ma la normalizzazione.
- **Nota:** rispondere sempre «stress» darebbe 1,00 su questa persona, perché non ha righe di riposo. Il suo risultato quindi non è confrontabile con quello degli altri.

C. Quanto il modello usa il movimento

Random Forest assegna a ogni colonna un punteggio di **importanza**: quanto quella colonna aiuta a separare stress e non stress. I punteggi sommano a 1.

gruppo	colonne	importanza
battito	bpm	0,35
sudore + temperatura	stress_skin, temp_sk1	0,04
movimento: medie (orientamento del polso)	accX/Y/Z_mean (Z da sola 0,18)	0,29
movimento: agitazione	accX/Y/Z_std e _var	0,32
movimento in totale	9 colonne	**0,61**

- **Perché è un campanello d'allarme:** l'obiettivo è riconoscere lo stress, ma il modello si appoggia soprattutto sul movimento. Quasi metà di quel peso viene dalle medie, cioè dalla postura: ogni fase ne ha una tipica (seduti al riposo, in piedi nel discorso, braccia che oscillano nella corsa). Anche il battito sale nella corsa per lo sforzo, non per lo stress. Sudore e temperatura quasi non vengono usati.
- **Il sospetto:** il modello riconosce in buona parte **che attività stai facendo**, più che se sei stressato. Il caso di ddca342b lo mostra su una persona reale.
- **Cautele:** l'importanza è un indizio, non una prova. Colonne collegate tra loro (per esempio std e varianza dello stesso asse) si dividono il punteggio, e questo tipo di importanza tende a favorire alcune colonne. Va detto «il 61% dell'importanza del modello», non «il 61% delle decisioni».

3. Prima di andare avanti: due domande

Il passo 2 dice che il classificatore funziona, ma non dice **che cosa** riconosce. Le fasi di stress sono anche fasi in cui ci si muove diversamente: nella corsa ovviamente, ma anche nel discorso (in piedi, si gesticola) rispetto al riposo (seduti, fermi). Il movimento è un possibile **confondente**: cambia insieme allo stress, ma non è lo stress. Dato che vale il 61% dell'importanza di Random Forest, e che il caso di ddca342b mostra che il modello usa la postura, vorrei chiedere alla prof se vale la pena controllarlo.

Domanda A — Confronto fisiologia / movimento

Cosa sarebbe: rifare il classificatore usando prima solo la fisiologia (battito, sudore, temperatura) e poi solo il movimento (accelerometro).

Perché ha senso: gli autori riportano proprio queste righe (Physio e Motion) nella Tabella 4. Rifarle completerebbe la replica e permetterebbe un confronto diretto con il paper.

Come chiederlo: «Il paper confronta anche solo fisiologia e solo movimento: lo rifaccio come parte della replica o passo direttamente alle feature nuove?»

Domanda B — Compito senza corsa

Cosa sarebbe: togliere la fase di corsa e classificare solo riposo contro calcolo + discorso.

Perché ha senso: nella corsa il movimento rende lo stress ovvio. Senza la corsa resta solo lo stress psicologico: se il modello funziona ancora, riconosce lo stress e non solo l'attività. Le classi sarebbero quasi pari (403 contro 400 righe), quindi il riferimento sarebbe 0,50 invece di 0,65.

Attenzione: non è nel paper, è un'idea mia.

Come chiederlo: «Le sembra utile provare anche un compito senza la corsa, per capire se il modello riconosce lo stress o solo il movimento? Potrebbe essere anche il banco di prova per le feature nuove.»

4. Le feature usate dagli autori (la lista chiesta dalla prof)

Fonte: Schreiber et al., *Stress Detection from Multimodal Wearable Sensor Data*, arXiv 2508.10468, sez. 3.6 (p. 8) e 4.1.2. In sintesi: per battito, sudore e temperatura **usano i valori già calcolati dal braccialetto** Corsano; le uniche feature che calcolano loro sono **media, deviazione standard e varianza dell'accelerometro**. Tutto è portato a un valore ogni 30 secondi e normalizzato per persona.

segnale	feature	file	chi la calcola
battito	bpm	activity	braccialetto
sudore	stress_skin (indice, 1 valore ogni 60 s)	emography	braccialetto
temperatura pelle	temp_sk1	temperature	braccialetto
movimento	media, dev. standard, varianza di accX, accY, accZ (9 feature)	acc (grezzo, 32 Hz)	**autori**
intervalli RR	eliminati: troppi dati mancanti	rr_interval	—
respirazione	eliminata: troppi dati mancanti	activity	—

Totale: 12 feature (3 fisiologiche + 9 di movimento). Nelle loro conclusioni gli autori scrivono che usare i dati grezzi a frequenza più alta dovrebbe migliorare i risultati: è esattamente lo spazio per il contributo del tirocinio.

Cosa non usano (i segnali grezzi)

file grezzo	contenuto	frequenza	cosa se ne può ricavare
ppg2_green / red / infra_red, ppg3	fotopletismografia (luce sul polso)	62,5 / 32 Hz	i singoli battiti e la variabilità del battito (HRV)
bioz	conduttanza della pelle	25 Hz	le singole reazioni di sudore (picchi)
acc	accelerometro X, Y, Z	32 Hz	magnitudine del movimento, indipendente dall'orientamento
heat_flux_sensor_temperature	temperatura della pelle	1 Hz	andamento fine: pendenza, variazioni

Il braccialetto perde quasi sempre gli intervalli RR durante lo stress (mancanti 68% nel calcolo, 89% nel discorso, 99,8% nella corsa): ricalcolarli dal PPG grezzo è il tentativo più interessante, ma anche il più rischioso.

5. I prossimi passi

Passo 4 — feature dai segnali grezzi

Un segnale alla volta, su finestre da **60 secondi** (in 30 secondi ci sono troppo pochi battiti per calcolare la variabilità). Le feature vengono da quelle viste nel progetto d'esame e dalla letteratura (es. WESAD).

n.	segnale	feature proposte	perché
1	sudore (bioz)	numero di reazioni, ampiezza media, intervallo fra reazioni, livello di fondo, pendenza	è il segnale classico dello stress; lo stress_skin del braccialetto è pieno di zeri
2	battito (PPG)	numero di battiti, intervallo medio, SDNN, RMSSD, pNN50	la variabilità del battito cala sotto stress; va misurato quanto PPG è utilizzabile
3	movimento (acc)	magnitudine del vettore accelerazione	misura quanto ci si muove senza dipendere dall'orientamento del polso (la postura)
4	temperatura (1 Hz)	media, deviazione standard, pendenza	la temperatura del polso scende sotto stress

Passi 5, 6 e 7

- **Passo 5 — classificatori con le nuove feature:** stesso codice del passo 2, aggiungendo un gruppo di feature alla volta. Domanda: le feature nuove migliorano il classificatore? (Se la prof è d'accordo, anche nel compito senza corsa della domanda B.)
- **Passo 6 — rete neurale (MLP):** una rete piccola con la stessa validazione, sulla tabella degli autori e su quella nuova, da mettere accanto ai sei classificatori.
- **Passo 7 — conclusioni e relazione:** tabella finale, discussione «stress o movimento?», limiti.

6. Cosa chiarire con la prof

Le domande sono in ordine di importanza. Le prime quattro cambiano la direzione del lavoro, le altre sono dettagli di metodo.

1. Confronto fisiologia / movimento: lo faccio?

È la domanda A della sezione 3. Sono le righe Physio e Motion della Tabella 4 del paper: rientrerebbe nella replica, ma non era nel piano concordato.

2. Compito senza corsa: ha senso?

È la domanda B della sezione 3. Idea mia, non nel paper: servirebbe a capire se il modello riconosce lo stress o solo il movimento.

3. Le feature nuove proposte vanno bene? In che ordine?

Mostrare la tabella della sezione 5 (sudore, battito, movimento, temperatura). Chiedere se ce ne sono altre «viste a lezione» da aggiungere, e se partire dal sudore.

4. Finestre da 60 secondi invece di 30?

Le feature sul battito richiedono almeno 60 s. Ma cambiare la finestra cambia anche il numero di righe: per un confronto onesto andrebbe rifatta anche la tabella degli autori a 60 s. Le chiedo se va bene.

5. Riferimento: Tabella 2 o Tabella 4?

Nel paper arXiv i titoli sembrano scambiati: il binario all'89% è la Tabella 4. Confermare quale citare.

6. Come trattare le incongruenze trovate nel paper?

Titoli scambiati, riga Motion uguale ad All, orientamento di ddca342b non menzionato, coda della temperatura a −8, frequenze dichiarate diverse da quelle reali. Vanno in un paragrafo della relazione? Ha senso segnalarle agli autori?

7. Normalizzazione per persona: va bene così?

La media e la deviazione standard di ogni persona sono calcolate su tutte le sue righe, comprese quelle di prova. Non usa le etichette ed è la scelta degli autori, ma in un uso reale non si avrebbero tutti i dati in anticipo. La dichiaro come limite o provo anche una variante (es. normalizzare con il solo riposo)?

8. Persone ddca342b e a5e823ad: come trattarle?

ddca342b ha il braccialetto orientato al contrario: la lascio così (è un caso reale), ruoto i suoi assi o aspetto le feature indipendenti dall'orientamento del passo 4? a5e823ad non ha un riposo valido: tenerla o escluderla dalla valutazione? Infine: la preparazione al discorso per ora è esclusa, è d'accordo?

9. Rete neurale: su cosa e con cosa?

MLP con scikit-learn o PyTorch? Sulle feature della tabella o, più avanti, direttamente sui segnali?

10. Relazione e tempi

Lunghezza e formato della relazione, scadenze, ogni quanto aggiornarla. Condividere la repo GitHub?

7. Scaletta della call (circa 10 minuti)

La frase da dire in call

«Ho rifatto la tabella e il classificatore degli autori: Random Forest fa 0,93 contro l'89% del paper. Ho preparato la lista delle feature che usano. Prima di calcolarne di nuove volevo chiederle due cose: il movimento vale più della metà dell'importanza del modello, e su una persona con il braccialetto girato il modello sbaglia quasi tutto il riposo. Mi chiedevo se vale la pena controllare quanto conta, rifacendo il confronto fisiologia / movimento del paper ed eventualmente togliendo la corsa.»

min	cosa dire	cosa mostrare
0–2	Tabella come gli autori: 1.145 righe da 30 s, 12 feature, pulizia minima	tabella della sezione 4
2–4	Replica riuscita: RF 0,93 contro 0,89. Due persone difficili: ddca342b ha il braccialetto girato (analisi fatta con l'aiuto di Claude), a5e823ad non ha il riposo	accuracy per persona, riquadro «Come raccontarlo alla prof»
4–5	Il movimento vale il 61% dell'importanza; ddca342b mostra che il modello usa la postura	importanza delle feature
5–7	Lista delle feature degli autori e proposta di feature nuove	sezioni 4 e 5
7–10	Domande: confronto fisiologia / movimento, compito senza corsa, feature nuove, finestre	sezioni 3 e 6

Glossario rapido

termine	in parole semplici
leave-one-subject-out	addestro su tutte le persone tranne una, provo su quella, ripeto per tutte
F1 macro	media della F1 di «stress» e «non stress»: penalizza un modello che ignora la classe meno numerosa
z-score per persona	a ogni valore tolgo la media della persona e divido per la sua deviazione standard
confondente	una variabile che cambia insieme a quella che voglio misurare (qui: movimento e stress)
importanza delle feature	quanto Random Forest usa ogni colonna per separare le classi
HRV (SDNN, RMSSD, pNN50)	misure di quanto varia l'intervallo fra un battito e l'altro